LABORATUVAR 7 · PAKETPRO 3000 · Paketleme Makinesi

AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad	Grup	Tarih
Merve Kurdi	225541602	06.11.2026

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

*Senaryo: PaketPro'ya YZ'li görsel paket kontrolü **eklenmesi planlanıyor** — proje aşaması değerlendirmesi yapıyorsunuz.*

Kamera → YZ Modeli → OK / RED → Ret mekanizması → Hat hızı

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

   İkinci bağımsız kontrol yapılır; kusurlu ürün otomatik OK sayılmaz.
   Şüpheli ürün ayrılır, operatör onayı istenir (human override).

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

   Kamera verisi bütünlük ve anomali kontrolleriyle incelenir.
   Şüpheli girişte otomatik karar durur, güvenli kontrol yoluna geçilir.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

   Doğrulanmış güven eşiğinin altında otomatik ret/OK kararı verilmez.
   Ürün ayrılır; manuel kontrol veya güvenli fallback uygulanır.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	Bağımsız kontrol + insan onayı
Girdi manipüle edildi	Girdi kontrolü + güvenli fallback
Confidence düştü	Güven eşiği + manuel inceleme

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.